

数据挖掘

第1讲：KDD 新范式与评估陷阱——从“跑通模型”到“真正可用”

汤世平 北京理工大学

在实验室里，你们的模型可能都能跑出极高的分数；但在这里，要教你们如何在真实世界里存活下来。

这门课的真正目标：

- 不是跑通模型，而是让模型在真实世界真正可用
- 从"完美 CSV"到"脏乱真实数据"的思维转变

那些光鲜亮丽的算法...

- 手写过反向传播
- 用 PyTorch 训练过 ResNet
- 用 XGBoost 刷过 Kaggle 或天池

这些课程教给你们的核心能力是什么？

给定一个完美的、已被清洗好的数据集，然后调用算法库去刷高准确率。




现实的骨感：当"完美 CSV"遇到真实世界

场景	数据现状
Kaggle/天池	干净数据集，排行榜刷分，规则明确
真实医院病历	错别字、缺失值高达 40%、判断标准矛盾
政务系统	中英文混杂、简拼全拼混用
社交媒体	饭圈缩写（yyds、u1s1）、违禁词拼音变体

你学过的几十种高阶算法，连输入格式都对不齐，一个都用不上。

	Score	Entries	Last	Join
	0.90365	6	6d	
	0.89532	19	6d	
	0.88272	13	2h	
	0.87987	7	7h	
	0.87926	4	11d	
	0.87743	6	11d	
	0.87215	3	15h	
	0.87093	8	2d	
	0.87032	2	20h	
	0.86991	2	2d	
	0.86930	5	28m	
	0.86707	2	2h	
	0.86565	3	1d	
	0.86341	4	11d	



典型案例：

- 生物：测序批次效应
- 经管：财务报表统计口径不一
- 医疗/政务：中英文混杂、简拼全拼混用
- 电商/社交：饭圈缩写（如 yyds）、拼音变体、网络黑话

三不教 (✗):

1. 不教怎么调用 Scikit-Learn (调包)
2. 不复习基础算法的数学推导
3. 不追求单纯的准确率跑分 (SOTA)

三必教 (✓):

1. **脏数据治理**: 标签噪声、缺失值、偏差修复
2. **复杂挖掘模式**: 图挖掘、流程挖掘、异常检测
3. **大模型自动化分析**: LLM + 工具 + 数据资产的 Agentic 范式

课程路线图：

- 第一部分（第 1–3 讲）：范式转移与数据评估（Data-Centric）
- 第二部分（第 4–5 讲）：模型诊断、归因与表格表示
- 第三部分（第 6–8 讲）：无监督模式进阶（聚类、过程挖掘、在线学习）
- 第四部分（第 9–11 讲）：复杂结构数据建模（图、知识图谱、时空轨迹）
- 第五部分（第 12–13 讲）：大模型驱动的自动化挖掘（Agentic EDA, GraphRAG）
- 第六部分（第 14–16 讲）：可信知识发现与因果推断

从"洗数据"到"挖知识"再到"自动化分析"及"因果推断"，六段递进式路线（共 16 次课）。

教材

- 数据挖掘原理与实践(基础篇), Charu C. Aggarwal, 王晓阳等译, 机械工业出版社, 2020

参考书

- 数据挖掘原理与实践(提高篇), Charu C. Aggarwal, 王晓阳等译, 机械工业出版社, 2020
- Data Mining: Concepts and Techniques, 4th Edition, Jiawei Han, Jian Pei and Hanghang Tong, 2023
- 数据挖掘:概念与技术(原书第3版), 韩家炜等著, 范明等译, 机械工业出版社, 2012

考核项目占比：

- 课堂讨论与出勤：10%
- 三次作业（弱监督、过程挖掘/漂移、Agent/RAG）：30%（各10%）
- 课程开源项目：60%

课程项目要求：

1. 谢绝任何玩具数据集
2. 组队（3-4人）
3. 提供代码仓库（要求代码可复现）
4. 个人贡献声明：每人的具体贡献

评分重心：数据质量改进、对照实验可信度、误差分析，**不看**基础模型调参刷分。

Part 1: KDD vs. Machine Learning

先分清：你在做"预测"，还是在做"发现"？

灾难案例：肺炎诊断模型

- 实验室表现：训练测试准确率 99%
- 部署到另一家医院：准确率跌至 50%

调查发现 (Clever Hans 效应):

- 重度肺炎病人大多躺着用便携式 X 光机拍
- X 光片带有特定金属标记
- 模型学会了识别"金属标记"而非肺部病变

虚假相关性——模型很聪明，但它总是找最省力的捷径。

从数据湖到知识结晶的漏斗：

- **原始数据** → 数据选择与集成 → 数据预处理与清洗
- → **数据挖掘** (发现模式) → 模式评估与解释
- → **可用知识** (规律、规则、图谱)

KDD 是一套端到端的方法论，目标是从海量、嘈杂的数据中提炼出**人类可理解、可行动的新知识**。

KDD 流程：从数据到知识



- [1] Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54.
<https://doi.org/10.1609/aimag.v17i3.1230>

Cross-Industry Standard Process for Data Mining

1. **Business Understanding**: 明确业务目标, 定义成功标准
2. **Data Understanding**: 收集数据, 探索数据特征
3. **Data Preparation**: 数据清洗、转换、特征工程
4. **Modeling**: 选择算法, 训练模型
5. **Evaluation**: 评估模型性能, 验证业务目标
6. **Deployment**: 将模型部署到生产环境

数据挖掘 (Data Mining) 是从大量数据中发现有用信息和知识的过程。

- 不仅仅是机器学习，而是一个更广泛的概念，涵盖了从数据收集、预处理到知识发现的整个流程。
- **数据挖掘**是KDD的一个核心环节，专注于从数据中发现模式和知识。

核心目标

- 帮助组织更好地理解其数据
- 提高业务效率与决策质量
- 提升收益并降低运营风险

核心理念：数据挖掘的本质是将原始数据转化为可行动的洞察，让数据说话，让数据驱动决策。



商业智能

- 市场趋势预测：识别消费者需求变化
- 竞争格局分析：洞察行业动态与机会
- 战略规划支持：数据驱动的决策制定

ROI提升：20–40%



风险控制

- 欺诈检测：实时识别异常交易行为
- 信用评估：精准预测违约风险
- 合规监管：自动化风险预警系统

损失降低：30–60%



运营优化

- 供应链管理：需求预测与库存优化
- 资源配置：提升运营效率
- 流程改进：识别瓶颈与优化点



个性化服务

- 精准营销：个性化推荐与定向投放
- 用户体验：定制化产品与服务
- 客户留存：预测流失并主动干预



数据挖掘的商业影响力

根据Gartner研究，采用数据挖掘技术的企业平均实现投资回报率提升35%

35%

平均ROI提升

01 分类 Classification

- 将数据项归入**预定义类别**的监督学习方法。通过学习历史数据的特征与标签关系，构建分类模型对新数据进行预测。

垃圾邮件识别、客户信用评分、疾病诊断

02 聚类 Clustering

- 基于数据间的**相似性自动分组**的无监督学习方法。无需预先定义标签，算法自动发现数据的内在结构。

客户细分、图像分割、文档聚类

03 关联规则 Association Rules

- 发现数据中**变量间的关联模式**，常用于购物篮分析、推荐系统等场景。

购物篮分析、商品推荐、交叉销售

04 异常检测 Anomaly Detection

- 识别**显著偏离常规**的数据点。在金融欺诈、设备故障、网络安全等领域至关重要。

欺诈检测、网络入侵检测、设备故障预警



技术选择原则：根据业务目标（预测/描述）、数据特征（有标签/无标签）、数据规模等因素选择合适的技术方法

	Machine Learning	KDD / Data Mining
核心目标	拟合已有标签，交付能预测的模型	发现可解释、可迁移的模式与结构
产出	指标（AUC/F1）、分数、决策函数	规律、群体差异、机制假设
核心问题	$f(X) = y$	从 X 中发现规律
已知量	任务目标 (y) 已知	连 y 是什么都不知道
成功标准	预测准确率	可解释性、新颖性、可行动性
典型场景	图像分类、推荐系统	关联规则、聚类、异常检测

你是在"刷预测分数", 还是在"从脏数据里挖出能解释、能落地的新知识"?

- **KDD**: 端到端方法论/流程 (从数据 → 可用知识)
- **Data Mining**: KDD 流程中的核心"挖掘算法"步骤
 - 关联规则挖掘、聚类、异常检测、序列模式等
- **Machine Learning**: 常用算法家族之一
 - 既可做预测, 也可做挖掘 (无监督/半监督)

核心视角差异: 预测 vs 发现

案例A：AlphaGo 下围棋

- 典型的 ML/RL 任务
- 规则确定，目标明确（追求胜率）
- 棋盘状态绝对清晰

规则确定、目标明确、标签清晰 → 这是 ML 最擅长的领域。



• [1] Silver, D., et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529, 484–489.

案例B：沃尔玛"啤酒与尿布"


- 经典教学引子（真实性有争议）
- 帮助理解"关联规则"
- 不应作为金标准证据

可核验实证：药物警戒不良反应检测

- 基于 FDA FAERS 等自发报告数据库
- 使用 disproportionality analysis
- 识别潜在不良反应信号
- 相关方法与结果都有可追溯文献

ML 追求"预测得准"；KDD 追求"解释得通，并发现全新知识"。

关联规则挖掘：啤酒与尿布



关联规则挖掘：从海量购物小票中发现"周末年轻父亲"的购物模式

Walmart / Osco Drug, 1992 · Apriori Algorithm

- [1] FDA Adverse Event Reporting System (FAERS). <https://www.fda.gov/drugs/questions-and-answers-fdas-adverse-event-reporting-system-faers>
- [2] Pham, M., et al. (2024). Adverse drug reaction signal detection methods in spontaneous reporting databases. *Pharmacoepidemiology and Drug Safety*.

经典 KDD 工业流程：


阶段	占比
数据准备	~80%
数据挖掘	~10%
模式评估与知识表示	~10%

常见现象（经验说法）：Data Engineer（DE）岗位数量通常显著多于 Data Scientist（DS）（可达数倍）

大多数人以为挖掘算法是核心，实际上**数据准备才是最耗时、最关键的环节。**

没有好数据，算法工程师就是无米之炊。

DE 是地基，DS 是地基上的建筑——地基不稳，建筑再华丽也会倒塌。



- [1] Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54.
- [2] “80/10/10”与“DE:DS 数倍”常用于强调数据工程投入在工业界的主导地位；不同组织与团队结构差异很大，建议按公司具体岗位分布或公开组织架构核验。

Part 2: "炼丹术"的黄昏

Model-Centric AI 的困境

核心范式:

Hold Data Fixed → Iteratively Improve the Code/Model


- 数据集锁死，全世界实验室比赛
- 全世界实验室竞相改进模型架构：你加 Attention，我换残差连接
- 试图把准确率从 99.1% 提高到 99.2%

俗称："炼丹术"

隐含假设（往往是错的）:

- 数据是干净的、无偏的、代表性充分的

学术内卷：ImageNet 刷榜史——为了 0.1% 的提升，参数量增加 10 倍



Garbage In, Garbage Out (垃圾进，垃圾出)

- 模型是数据的忠实镜像
- 数据有偏差 → 模型学到偏差
- 数据有噪声 → 模型拟合噪声
- 数据有泄漏 → 模型学到捷径，而非真实规律

核心问题：现实数据充满人类社会的系统性偏差 (Systematic Bias)


更大的模型 $\neq$ 更强的鲁棒性。复杂模型反而会精准地拟合数据中的系统性错误。

最著名的人工智能歧视案例：

- 亚马逊开发 AI 简历筛选系统
- 使用过去 10 年公司录用程序员的简历数据训练
- 极度歧视女性候选人
- 简历出现"女子大学"、"女子象棋俱乐部" → 直接降分淘汰

思考：换一个参数量大 100 倍的模型能解决吗？

答案：情况会更糟！复杂模型会更敏锐地捕捉历史上的系统性毒素，产生更隐蔽、更极端的歧视。



• [1] Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*.

身边的系统性偏差：

场景	偏差表现
招聘场景	过度拟合"第一学历（985/211）"、严重的"35岁歧视"
早期语音识别	对普通话标准人群准确率极高，对地方口音（川普、广普）识别率极低

根本原因：训练数据中特定群体代表性严重不足。

医学图像中的 Clever Hans：

- 深度学习模型诊断肺炎 X 光片，实验室准确率奇高
- 在真实医院部署后完全失效

可解释性分析揭示根因：

- 重症肺炎患者多在重症监护室拍卧式 X 光片，与普通门诊拍摄的立式 X 光片风格差异巨大
- 片子右上角带有特定型号仪器的金属刻度标记
- 患有重症肺炎的病人往往已经插上了呼吸机管路、胸腔引流管，或者身上贴着心电图电极片

AI学会的...

- 识别X光机的类型
- 识别右上角金属刻度
- 识别管子

Clever Hans 的本质：模型不过只是诚实地反映了你数据收集过程中的瑕疵

Part 3: Data-Centric 范式崛起

吴恩达的 Data-Centric AI 倡议


Andrew Ng (吴恩达):

- 2021 年提出: 必须从 Model-Centric 转向 Data-Centric AI

核心论点:

- 在大多数真实工业场景中, 模型架构已经足够好
- 瓶颈在于数据质量, 而非模型复杂度
- 改变代码/模型的收益已见顶, 且容易过拟合系统性偏差

既然改模型收益见顶, 为什么不把重心放在迭代地改善数据质量上?




- [1] Ng, A. (2021). MLOps: From Model-centric to Data-centric AI. *DeepLearning.AI / Stanford HAI*.
- [2] Zha, D., et al. (2023). Data-centric AI: perspectives and challenges. *SIAM SDM*.

吴恩达钢板缺陷检测实验：

干预方式	准确率	提升
Baseline	76.2%	—
优化模型架构（ResNet 变体，花费数周）	76.2%	+0%
统一标注标准 + 重标数据（花费两天）	93.1%	+16.9%

关键动作：把数据标注团队叫到一起，统一"多长、多深的划痕才算缺陷"的定义，模型没有任何改变。

在小样本工业和科学场景中，花 1 天洗数据，胜过花 10 天调超参。



• [1] Ng, A. (2021). MLOps: From Model-centric to Data-centric AI. 钢材表面缺陷检测实验 (76.2% → 93.1%)。

为什么数据清洗如此重要？

样本编号	缺陷图片	标注员A	标注员B	清洗后统一标签
001	(微小划痕图)	划痕	无缺陷	划痕（按新标准）
002	(边缘瑕疵图)	无缺陷	划痕	无缺陷

当 Ground Truth 本身就是错的时，模型上限被亲手压低。

支柱 1: 标签一致性 (Label Consistency) 与脏数据治理

- 统一标注规范, 消除标注者间分歧
- 鲁棒损失函数应对噪声标签
- 主动学习发现数据中的"脏样本"

支柱 2: 数据合成与增强 (Data Augmentation)

- 针对长尾特征进行定向增强
- 合成数据补充稀缺类别

支柱 3: 领域规则注入与弱监督学习 (Data Programming)

- 利用 Snorkel 等框架, 写启发式规则自动生成弱标签
- 让领域知识直接编码进数据

国内"数据标注产业"正经历从劳动密集型到医生/硕博生参与 RLHF 的知识密集型转型

• [1] Ratner, A., et al. (2017). Snorkel: Rapid training data creation with weak supervision. *VLDB*, 11(3).

• [2] Matthews, C. et al. (2004). On Select Learning: Estimating uncertainty in dataset labels. *MLP*, 70.

不仅仅是"无缺失值":

维度	含义
一致性	同一概念的定义和编码统一
无偏性	样本分布代表真实总体
时效性	数据反映当前真实状态
代表性	覆盖所有重要子群体
完整性	关键字段无缺失

数据质量是多维度的工程问题，不是一个 `dropna()` 能解决的。

五步法：把"洗数据"变成可执行工程

1. **固定基线**：模型与评测协议固定
2. **切片诊断**：按人群/场景/设备/时间段定位失败模式
3. **找根因**：标签规范不清、采样偏差、测量偏差、泄漏、重复样本
4. **改数据**：重标/补采/去重/去毒/规则注入/增强/合成
5. **回归验证**：同一模型下对比，建立数据版本与审计

否则你永远说不清效果是怎么来的。

Data-Centric 体验：

- 每组 10 条"边界样本"（钢材表面划痕是否算缺陷）
- 每个人先独立标注
- 组内讨论统一标准
- 统计全班标注一致率

学习目标：直观感受"标签定义不清时，模型上限被亲手压低"。

第一阶段：独立标注

请不要与周围同学交流，根据你的第一直觉对以下 10 个边缘样本进行标注（勾选）。

样本编号	样本描述（假设你看到的是对应的质检图像）	你的独立标注
001	表面有一条长度约 2mm 的极细微划痕，仅在特定反光角度下可见。	☐ 缺陷 ☐ 正常
002	表面有一块面积约 1cm ² 的水渍/油渍印记，可擦除，无物理损伤。	☐ 缺陷 ☐ 正常
003	钢材边缘有轻微的毛刺（处于加工容差范围内，不影响后续拼接）。	☐ 缺陷 ☐ 正常
004	表面颜色分布不均，有一块暗斑，但用手触摸表面绝对平整。	☐ 缺陷 ☐ 正常
005	包含 3 条长度均不到 1mm 的极微小划痕，但它们密集分布在同一区域（群聚状）。	☐ 缺陷 ☐ 正常
006	表面有一条长达 5mm 的划痕，但极其浅，手指触摸无任何凹凸感。	☐ 缺陷 ☐ 正常
007	表面有一处直径 0.5mm 的小凹坑（沙眼），但该批次钢材用于隐藏的内部结构。	☐ 缺陷 ☐ 正常
008	由于摄像机镜头上有灰尘，导致图片中央有一个模糊的黑点，不确定是否是钢材本身的黑点。	☐ 缺陷 ☐ 正常
009	钢材表面印有出厂二维码时的墨水发生轻微晕染、扩散。	☐ 缺陷 ☐ 正常
010	有一条极长的严重划痕（10cm），但位于最边缘区域，在后续切割工序中注定会被直接裁掉。	☐ 缺陷 ☐ 正常

第二阶段：组内讨论与标准统一

请与你的小组成员（2-4人）交流，统计你们独立标注的不一致率。然后尝试达成完全统一的标注结果。在讨论过程中，请记录你们为了达成共识而制定的“标注规范（Annotation Guideline）”。

你们小组制定的标注规范：

1. 关于划痕长度和深度的标准： _____
2. 关于可擦除污渍/水渍的标准： _____
3. 关于非物理损伤（颜色暗斑、墨水晕染）的标准： _____
4. 关于图像设备噪声（如镜头灰尘）的处理规则： _____
5. 关于边缘/废料区域的缺陷是否应标出的规则： _____

统一后的最终标签（Consensus Labels）：

001	002	003	004	005	006	007	008	009	010

Scaling Law 的核心结论：

- 模型性能由参数量N、数据量D、算力C共同决定
- 三者协同扩展，性能才能持续提升

数据枯竭危机 (Data Wall)：

- 高质量、可用、可授权的数据增长速度放缓
- 业界普遍担忧未来几年高质量数据成为瓶颈

中文高质量数据墙：

- 营销号泛滥、头部厂商清洗壁垒
- 文化对齐挑战 (Alignment)

掌握 Data-Centric 思维是通往 AGI 的必经之路。

Part 4: 评估陷阱详解

目标泄漏 / 时序穿越 / 子群体偏见

从 Data-Centric 到 LLM 的具体映射：

LLM 阶段	Data-Centric 工作
预训练	去重、质量过滤、去毒、领域配比、时间切分与泄漏控制
对齐（SFT）	指令数据质量、任务覆盖面、格式一致性
对齐（RLHF/DPO）	偏好数据覆盖面与一致性、边界案例处理
评测	评测集与红队集本质也是"数据资产"

Model Collapse（模型崩溃）现象：


- 用 AI 生成的数据训练下一代 AI
- 多代迭代后，模型输出分布逐渐退化
- 最终产生完全无意义的乱码——"赛博精神病"

根本原因：

- 合成数据的分布是真实数据分布的有损压缩
- 每一代训练都在放大这种损失
- 尾部分布（罕见但重要的知识）最先消失

2024 年 Nature 论文：《The Curse of Recursion》

合成数据需要**严格过滤与真实数据锚定**，否则是慢性毒药。



• [1] Shumailov, I., et al. (2024). The curse of recursion: Training on generated data makes models forget. *Nature*, 631, 755–759.

陷阱1：目标泄漏（Target Leakage）

定义：模型训练时，特征中包含了在真实预测发生时绝对无法获取的未来信息

快速自查口令：

- 这个特征在"预测时刻"真实可得吗？
- 是由标签"反推"得到的吗？

类比：考前偷看答案

陷阱2：时序穿越（Time-Travel Leakage）

定义：处理时间属性数据时，使用未来信息预测过去


原因：盲目使用 `train_test_split`

快速自查口令：

训练集是否包含"晚于测试集"的时间点？

错误 vs 正确：

- ✗ 错误：训练集看到"双11买了 iPhone"，测试集预测"10月份是否会加购"
- ✓ 正确：用 1-9 月训练，用 10 月测试



陷阱3：子群体偏见 (Subpopulation Bias)

定义： 整体指标极高，但在关键少数群体上表现惨不忍睹

原因： 算法主动"讨好"多数样本

快速自查：

业务风险是否集中在某个小群体？

表现：整体召回率 90%，看似完美

拆解表格：

机构类型	样本占比	模型召回率	实际业务风险
大城市三甲	90%	95%	低
偏远小诊所	10%	20%(危!)	极高

只看整体报告上线，导致偏远地区医保资金大规模被盗刷。

这段代码的坑在哪？

```
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X_all) # 对全部数据标准化  
X_train, X_test = train_test_split(X_scaled, y, test_size=0.2)
```

揭秘： `fit_transform(X_all)` 导致测试集均值方差泄漏给训练阶段

正确做法：使用 Pipeline 或先切分再 fit

本周实战 + 思考题：

基础目标（MVP 实验）：

- "挖坑"数据集竞速（包含隐蔽泄漏点）
- 体验"虚假繁荣跌回现实"
- 提交：审计报告 + 可运行代码 + 对比表

深度思考题：

1. 当评估方案本身存在系统性偏差时，模型架构提升是否是"幻觉"？
2. 如果原始数据存在严重系统性缺陷，换参数量大 10 倍的模型能解决吗？

Part 5: 总结与展望

数据决定天花板，模型只是逼近天花板的工具

三条核心结论：

1. **思维转变**：拥抱 Data-Centric，数据质量决定模型上限
2. **避开陷阱**：警惕目标泄漏、时序穿越、子群体偏见
3. **严守规范**：没有严密评估，实验就是"闭门造车"

"数据是天花板，模型只是逼近这个天花板的工具。"

在你目前的研究方向中，阻碍你的究竟是：

- **A** 好的模型（更强的算法、更深的网络）
- **B** 好的数据（更干净、更无偏、更有代表性的数据集）

第2讲：脏数据治理与可操作的数据质量策略

- 缺失机制 (MCAR/MAR/MNAR) + 多重插补 (Multiple Imputation): 统计学视角下的缺失值处理
- 标签噪音 (Noisy Labels): 当 Ground Truth 本身就是错的时怎么办
- 高阶治理: 对抗分布漂移的填补策略与数据质量度量
- 自动化质量监控: 特征分布监控 Dashboard 的设计逻辑

下节课，我们将正式进入技术实操环节。

1. Fayyad, U., Piatetsky–Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17(3), 37–54.
2. Silver, D., et al. (2016). Mastering the Game of Go with Deep Neural Networks and Tree Search. *Nature*, 529, 484–489.
3. Dastin, J. (2018). Amazon Scraps Secret AI Recruiting Tool that Showed Bias Against Women. *Reuters*.
4. Zech, J. R., et al. (2018). Variable Generalization Performance of a Deep Learning Model to Detect Pneumonia in Chest Radiographs. *PLOS Medicine*, 15(11).
5. Lapuschkin, S., et al. (2019). Unmasking Clever Hans Predictors and Assessing What Machines Really Learn. *Nature Communications*, 10, 1096.
6. Ng, A. (2021). MLOps: From Model–Centric to Data–Centric AI. *DeepLearning.AI*.
7. Ratner, A., et al. (2017). Snorkel: Rapid training data creation with weak supervision. *VLDB*, 11(3).
8. Northcutt, C., et al. (2021). Confident learning: Estimating uncertainty in dataset labels. *JAIR*, 70.

9. Zha, D., et al. (2023). Data-centric AI: perspectives and challenges. *SIAM SDM*.
10. Kaplan, J., et al. (2020). Scaling laws for neural language models. arXiv:2001.08361.
11. Hoffmann, J., et al. (2022). Training compute-optimal large language models (Chinchilla). arXiv:2203.15556.
12. Pham, M., et al. (2024). Adverse drug reaction signal detection methods in spontaneous reporting databases. *Pharmacoepidemiology and Drug Safety*.
13. Shumailov, I., et al. (2024). The curse of recursion: Training on generated data makes models forget. *Nature*, 631, 755–759.