

7分钟答辩讲稿

建议语速：每分钟 180-220 个中文字符。整体结构保持“问题背景 → 数据介绍 → 技术方案 → 实验结果 → 总结演示”，页数从 10 页扩展到 20 页。

Slide 1 封面

大家好，我们小组的项目是《社交媒体情感分析的跨域泛化》。这次扩展版汇报仍然围绕一个核心问题：在评论数据上训练好的模型，为什么迁移到微博这种社交媒体文本后会明显失效，以及我们怎样用数据层改进和可复现实验去缩小这个差距。封面右侧三个数字先给出结论：目标域有 6000 条微博样本，其中 3600 条用于弱监督伪标注；最佳目标域 Macro-F1 达到 0.927；最平衡的跨域衰减 DeltaF1 是 -0.019。后面的汇报会依次说明问题、数据、方法、证据和最终交付。

Slide 2 汇报顺序保持五段结构

汇报结构保持原来的五部分，但每一部分增加一页细节或证据。第一部分讲问题背景和评价约束；第二部分讲数据来源、划分和偏移审计；第三部分讲系统架构、方法矩阵和训练评估协议；第四部分讲实验结果、消融、负向发现和失败案例；第五部分总结贡献、局限和演示过渡。这样页数从 10 页扩展到 20 页，但叙事顺序不变。

Slide 3 问题背景：源域模型直接迁移到微博会遇到双重偏移

这一页解释为什么这个题目不是简单的情感分类。源域是外卖评论，表达方式更集中在口味、配送、服务等消费体验上，标签也比较均衡。目标域是微博，文本里经常有转发链、表情、反讽和社会事件语境，而且我们刻意构造负:正=2:1，模拟舆情监测中负面声音偏多的场景。因此，源域学到的词面模式迁移到微博时会失效，负面召回也会变得更重要。

Slide 4 评价目标不能只看目标域 F1

这一页补充评价目标。跨域任务里，单看目标域 F1 不够，因为模型可能通过牺牲源域稳定性换取目标域分数，也可能因为阈值选择导致负面召回不足。所以我们同时看 Macro-F1、Weighted-F1、AUC、DeltaF1 和目标域负面召回率。DeltaF1 越接近 0，说明源域和目标域表现越平衡；负面召回率则对应舆情监测中漏报负面信息的风险。

Slide 5 数据介绍：正式数据不是示例数据

本页说明数据规模。源域来自 ChineseNlpCorpus 的 waimai_10k，处理后 8000 条；目标域来自 HuggingFace 的 weibo_senti_100k，处理后 6000 条。目标域进一步切分成 train、val、test 和 unlabeled，其中 3600 条未标注样本用于弱监督伪标注。这一点很关键，因为中期阶段可能只是 smoke benchmark，而最终版已经换成真实公开语料，并且目标域满足 5k+ 的规模要求。

Slide 6 数据划分为方法设计服务

这一页把数据划分和方法联系起来。源域主要用于训练基础情感分类能力；目标域 train 很小，只占 600 条，用于模拟现实中人工标注昂贵的情况；目标域 unlabeled 有 3600 条，适合弱监督伪标注；目标域 val 用来调阈值，尤其要约束负面召回；test 则只在最终报告中使用时。这样做的好处是每个模块都对应一个明确的数据来源，避免训练和评估混在一起。

Slide 7 数据偏移来自文本风格、长度和语义触发词

这一页进一步解释为什么目标域更难。微博文本平均长度约 51.9 字，比源域评论长得多，里面常常有转发链、表情符号、社会事件实体和反讽表达。源域里的“好吃、配送、服务”等词，迁移到微博时不一定有同样意义；微博里的“哈哈、祝福、鼓掌”也可能出现在负面或讽刺语境中。因此我们不仅需要模型，还需要错误案例和失败模式分析。

Slide 8 技术方案：从公开语料到可复现实验闭环

这一页展示系统架构。流程从公开语料开始，经过 TextCleaner 做去噪、去重和字段统一，然后生成 source_full 和 social_full 两个正式数据文件。接着进入特征编码和 E0-E6 实验矩阵，每个方法跑 3 个随机种子，并在目标域验证集调阈值。最后输出 JSON、CSV、PNG 图表和 PDF/Markdown 报告。架构重点不是只跑一次模型，而是让数据、代码、结果和报告可以互相追溯。

Slide 9 可复现性设计：不是只交 PPT，而是交实验系统

这一页补充可复现性。最终交付不只是 PPT 和报告，而是包含数据准备、实验运行、报告生成和验证脚本。别人可以运行 `run_final` 重新生成结果，也可以用 `verify_final` 快速检查已有产物是否完整。报告中的数据规模、实验指标和错误样本都来自本地结果文件，而不是手工填写。这个设计能减少答辩时最常见的问题：数字从哪里来、结果能不能复跑、失败案例是不是临时编的。

Slide 10 技术方案：E0-E6 隔离每个模块的贡献

这一页是方法矩阵。E0 是 TF-IDF+LR 的源域基线，给出下限；E1 增强 lexical encoder，加入字符 n-gram 和情感词典；E2 加入弱监督伪标注；E3 使用少量目标域金标做 adapter calibration；E4 组合伪标注和 adapter；E5 做领域特征过滤；E6 使用 char1-5 更宽的特征空间作为 backbone 替换。这样每个模块都有可比较的对照。

Slide 11 训练与评估协议：阈值选择也纳入实验

这一页解释训练逻辑。对于每个方法，训练数据从源域开始，如果启用伪标注，就加入目标域 unlabeled 中的高置信样本；如果启用 adapter，就加入加权的目標域 train 金标样本。模型训练后，不直接用默认 0.5 阈值，而是在目标域验证集上搜索最优阈值，同时让负面召回尽量不低于 0.85。最后再在源域和目标域测试集上报告结果。

Slide 12 基线证明：source-only 迁移存在明显衰减

这一页先看基线。E0 的目标域 F1 只有 0.625，E1 增强 lexical 特征后也只有 0.644，说明单纯把源域模型迁移到微博仍然有明显衰减。E1 的负面召回达到 0.873，但正例召回较弱，说明它更偏向预测负面，不能代表整体分类能力好。因此后面需要伪标注、目标域校准和更宽特征空间来补充目标域信号。

Slide 13 实验结果：E3 目标域 F1 最佳，E6 跨域衰减最平衡

这一页展示最终结果图。蓝色是目标域 Macro-F1，绿色是负面召回，黄色是目标域 AUC。可以看到 E3 的目标域 F1 最高，达到 0.927，负面召回也达到 0.958；E6 的目标域 F1 是 0.890，但 DeltaF1 只有 -0.019，是源域和目标域表现最平衡的方法。E5 虽然负面召回不低，但 F1 明显回落，后面会作为负向消融分析。

Slide 14 为什么 E3 与 E6 是两个不同意义上的最优

这一页解释结果，不只是报数字。E3 使用少量目标域金标样本做校准，所以它最直接地补上了目标域语境和类别分布信息，目标域 F1 最好。E6 使用 char1-5 更宽特征空间，它未必达到最高目标 F1，但源域和目标域之间的差距最小，说明特征覆盖更均衡。因此如果业务只关心微博舆情上线效果，可以优先考虑 E3；如果课程实验强调跨域泛化稳定性，E6 是很重要的补充结论。

Slide 15 消融证明：伪标注和校准有效

这一页讲正向消融。E1 是增强特征但只用源域训练，目标 F1 为 0.644。加入弱监督伪标注后，E2 提升到 0.753，说明 unlabeled 目标域数据确实提供了有用的目标域词面信号。E3 加入少量目标域金标校准后提升到 0.927，是最大提升来源。这个结果说明，在跨域情感分析里，少量高质量目标域标注比盲目堆模型更关键。

Slide 16 负向发现：分布距离降低不等于分类效果更好

这一页讲负向消融。E5 做领域特征过滤，目标是去掉强领域特异 n-gram，模拟 domain-adversarial 的效果。它确实把 MMD 从 0.049 降到 0.016，但目标 F1 只有 0.681，明显低于 E2、E3 和 E6。原因是过滤过强时，可能把微博目标域里的关键情感触发词也删掉了。这说明跨域对齐不能只看分布距离，还要看任务指标和错误样本。

Slide 17 失败案例：正向词并不总是正向情绪

这一页展示具体错误。样本里有很多“美味、太香、不错”这样的正向词，所以 E0 预测为正面；但真实标签是负面，因为整体语境里有“吃多了、抓狂”等负面体验。线性 n-gram 模型容易抓住局部词面，却没有能力理解跨句语义和反讽。这类失败案例说明，最终模型即使指标提升，也仍然需要上下文编码器、表情特征和困难样本主动学习来继续改进。

Slide 18 局限性：CPU 友好版本牺牲了深层语义建模

这一页承认局限。为了保证课程环境中无 GPU、无外部账号也能复现，最终可运行实验使用 lexical/hash 特征来模拟完整迁移框架。这让 E0-E6 消融非常快、非常稳定，但对长转发链、反讽、表情和跨句语义的建模能力弱于 BERT/RoBERTa。后续工作可以在保持同一数据 split 和同一评估协议的基础上，加入上下文编码器、人工一致性评估和更精细的错误类型标注。

Slide 19 总结：目标域校准最有效，跨域平衡需要更宽特征空间

最后总结三点贡献。第一，使用真实公开数据构建了源域 8000 条、目标域 6000 条的跨域情感任务；第二，完成 E0-E6 消融矩阵，每个方法 3 个随机种子并报告均值和标准差；第三，形成了数据准备、实验运行、结果验证和报告生成的可复现闭环。关键结论是：E3 目标域校准最有效，E6 跨域衰减最平衡，E5 提醒我们不能只看分布距离。接下来可以进入 3 分钟系统演示，展示这些产物如何被验证。