

社交媒体情感分析的跨域泛化：最终项目报告

0. 项目基本信息

- **项目名称**：社交媒体情感分析的跨域泛化：面向分布偏移的 Data-Centric 改进
- **仓库链接**：https://github.com/MarBarb/sentiment-cross-domain
- **团队成员**：李乘黄、马啸、THAM WAN HEI、化润宇
- **最终交付日期**：2026-06-03
- **复现命令**：`PYTHON=/path/to/python ./scripts/run\_final.sh`

1. 问题定义与目标

项目目标是从评论源域迁移到微博社交媒体目标域，构建二分类情感模型。重点不是单一模型堆叠，而是验证数据层诊断、弱监督伪标注、少量目标域适配、领域特征过滤和特征 backbone 替换对跨域性能衰减的影响。

验收指标包括 Macro-F1、Weighted-F1、AUC、DeltaF1、目标域负面召回率，以及特征层 KL/MMD 诊断。

2. 数据来源与审计

数据来自公开语料，可由 `scripts/prepare\_real\_data.py` 重新生成：

- 源域：ChineseNlpCorpus `waimai\_10k`，下载地址：https://raw.githubusercontent.com/SophonPlus/ChineseNlpCorpus/master/datasets/waimai_10k/waimai_10k.csv
- 目标域：HuggingFace `dirtycomputer/weibo\_senti\_100k`，下载地址：
https://huggingface.co/datasets/dirtycomputer/weibo_senti_100k/resolve/main/weibo_senti_100k.csv

域	raw rows	processed rows	train	val	test	unlabeled	正例比例	平均长度
源域 waimai review	11987	8000	5600	1200	1200	0	50.0%	22.9
目标域 weibo social	119000	6000	600	600	1200	3600	33.3%	51.9

目标域按负:正=2:1 构造，模拟社会事件评论中负面/质疑声音偏重的场景；仅 10% 作为有标注训练集，60% 作为未标注数据用于弱监督伪标注。

3. 方法与消融矩阵

最终实验覆盖 **E0-E6** 七个方法，并对每个方法运行 3 个随机种子。

ID	方法	说明
E0	TF-IDF+LR source-only	浅层 TF-IDF+LR，仅源域训练。
E1	Source-only strong lexical encoder	增强 lexical encoder，仅源域训练，加入情感词典特征。
E2	Weak supervision pseudo labels	弱监督伪标注，从目标域 unlabeled 中选高置信样本加入训练。
E3	Target adapter calibration	目标域 adapter calibration，使用少量目标域金标样本进行适配。
E4	Weak supervision + adapter	弱监督 + adapter 组合。
E5	Domain-adversarial feature filtering	领域特征过滤，模拟 domain-adversarial 去除强域特异 n-gram。
E6	Backbone replacement char1-5	backbone 替换，使用 char1-5 更宽特征空间。

4. 最终实验结果

所有结果均为 3 个随机种子 (42/123/456) 的均值与标准差。

ID	F1(source)	F1(target)	DeltaF1	AUC(target)	Neg Recall	Pos Recall	Weighted-F1
E0	0.848±0.001	0.625±0.003	0.223±0.002	0.685	0.718	0.541	0.663
E1	0.866±0.003	0.644±0.003	0.222±0.001	0.719	0.873	0.402	0.698
E2	0.852±0.006	0.753±0.006	0.099±0.012	0.834	0.879	0.609	0.784
E3	0.860±0.001	0.927±0.001	-0.068±0.002	0.980	0.958	0.892	0.936
E4	0.848±0.001	0.897±0.007	-0.049±0.007	0.963	0.913	0.894	0.908
E5	0.851±0.001	0.681±0.005	0.170±0.005	0.775	0.898	0.443	0.729
E6	0.871±0.015	0.890±0.005	-0.019±0.020	0.962	0.935	0.840	0.903

目标域 F1 最佳方法为 **E3 Target adapter calibration**，F1(target)=0.927，负面召回=0.958。

DeltaF1 最平衡方法为 **E6 Backbone replacement char1-5**，DeltaF1=-0.019。

结论：少量目标域金标校准 (E3) 是收益最大的模块；弱监督伪标注 (E2) 能将目标域 F1 从 E1 的 0.644 提升到 0.753；E5 虽然降低了 MMD，但过度过滤导致正例召回下降，是一个负向消融。

5. 错误分析

错误样本保存在 `results/final\_error\_cases.csv`。主要失败模式包括：

- 微博文本中大量转发链、表情和反讽表达，线性 n-gram 模型容易把局部正向词误判为整体正向。
- 目标域中“祝福/哈哈/鼓掌”等词在不同语境下可能同时出现在正负样本中，造成词面冲突。
- 领域特征过滤能够降低 MMD，但如果过滤过强，会删除目标域关键情感触发词。

6. 复现与交付

核心命令：

```
PYTHON=/Users/lichenghuang/.cache/codex-runtimes/codex-primary-runtime/dependencies/python/bin/python3 .  
/scripts/run_final.sh  
PYTHON=/Users/lichenghuang/.cache/codex-runtimes/codex-primary-runtime/dependencies/python/bin/python3  
scripts/verify_final.py
```

核心产物：

```
- `data/processed/source_full.csv`  
- `data/processed/social_full.csv`  
- `results/final_metrics.json`  
- `results/final_summary.csv`  
- `results/final_error_cases.csv`  
- `results/final_metrics_chart.png`  
- `report/final_report.md` / `report/final_report.pdf`
```

7. AI 工具使用声明

项目使用 ChatGPT/Codex 辅助代码补全、实验脚本整理、报告生成与调试；数据处理、指标解释和最终结论均以本地可复现运行结果为准。