

数据挖掘课程项目中期进展报告

社交媒体情感分析的跨域泛化：面向分布偏移的 Data-Centric 改进

项目链接：<https://github.com/MarBarb/sentiment-cross-domain> 报告日期：2026-05-30

中期交付说明：本次不只整理报告，也补齐了本地样例数据、CSV 加载、TF-IDF+LR 基线、阈值扫描、指标保存、预测明细与对比图。完整 BERT/RoBERTa 实验进入终期冲刺。

姓名	学号	角色	已完成贡献	后续规划
李秉黄	3220251475	数据工程、浅层基线	数据来源规划、文本清洗、样例数据与轻量基线	扩展真实目标域数据，完成 E0 与审计图表
马啸	3220251484	主干模型与实验调度	BERT/RoBERTa 框架、Adapter/LoRA 方案	跑通 BERT source-only、Adapter 和 KL 对齐
THAM WAN HEI	3820251057	弱监督与人工评测	Snorkel 规则伪标注、人工标注流程设计	完成 E2、人工复核与 Kappa 统计
化润宇	3220251231	分布诊断与对抗适配	KL/MMD、DANN、RoBERTa 对比设计	完成 DANN、RoBERTa 消融与可视化

1. 项目概述与代码状态

- 任务目标：从影评/书评源域迁移到社会事件评论目标域，降低概念漂移下的情感分类性能衰减。
- 中期状态：原仓库已有模型、训练、评测、配置骨架；本次补丁完成了一个可运行 smoke benchmark，使数据清洗、特征抽取、训练、阈值搜索、评测和结果保存形成闭环。
- 公开仓库全部分支可见 commit 数 5 次，main 分支 4 次；活跃 Git 身份为 MarBarb、wanhei、wanheil。

本地中期新增交付	说明
data/processed/source_sample.csv, social_sample.csv	源域影评/书评样例与目标域社会事件评论样例
src/data/local_loader.py	CSV 读取、split 检查和数据审计统计
src/baselines/tfidf_lr.py	字符 n-gram TF-IDF 与手写 Logistic Regression
src/evaluation/metrics.py	无 sklearn 依赖的 Macro-F1、AUC、负面召回和阈值搜索
run.py, scripts/run_midterm_smoke.sh	中期一键复现实验入口
results/*.json, *.csv, *.png	指标、逐样本预测和对比图

```
sentiment-cross-domain/  
■■■■ data/processed/{source_sample.csv, social_sample.csv}  
■■■■ src/{baselines,data,models,training,evaluation}/  
■■■■ scripts/run_midterm_smoke.sh  
■■■■ results/{midterm_tfidf_metrics.json, midterm_tfidf_predictions.csv, midterm_metrics_chart.png}  
■■■■ report/midterm.md
```

2. 数据工程与审计落地

数据划分	样本数	正例	负例	正例比例	平均字符数
源域 train	32	17	15	53.1%	12.38
源域 test	12	6	6	50.0%	11.67
目标域 train	20	8	12	40.0%	13.40
目标域 val	9	3	6	33.3%	12.22
目标域 test	12	4	8	33.3%	12.67
数据问题	量化规模	解决方案		效果	
目标域类别不平衡	test 为 8 负 / 4 正，正例比例 33.3%	compute_metrics 增加 recall_negative ; datamodule 计算 pos_weight		报告同时给出 Macro-F1 与负面召回	
词面 domain shift	源域 1258 个 char n-gram，目标域 1283 个，共享 44 个，Jaccard=0.0176	实验 JSON 记录 char n-gram audit		证实目标域校准和语义模型有必要	
原仓库缺少数据	原 data 目录仅有 .gitkeep	新增样例 CSV 与 local_loader		smoke benchmark 可复现	
社媒噪声	清洗器覆盖 mention、hashtag、URL、emoji 重复字符、广告语	TextCleaner.clean		规则可运行，终期需统计真实噪声占比	

数据流与预处理管道



3. 基线模型与核心算法实现

已跑通方法：E0-lite 仅使用源域样例训练 TF-IDF+LR；E1-lite 使用源域样例加少量目标域 train 样本校准，目标样本权重 0.5。

```
■■■■■■  
cd sentiment-cross-domain  
PYTHON=/Users/lichenghuang/.cache/codex-runtimes/codex-primary-runtime/dependencies/python/bin/python3 ./scripts/run_midterm_smoke.sh
```

```
■■■■■■  
INFO:__main__:Experiment source_only complete.  
INFO:__main__:Metrics saved to results/midterm_tfidf_metrics.json  
INFO:__main__:Predictions saved to results/midterm_tfidf_predictions.csv
```


模块	文件	状态	备注
文本清洗	src/data/cleaner.py	完成	6 类社媒噪声规则

模块	文件	状态	备注
本地数据加载	src/data/local_loader.py	完成	CSV 读取、split 检查、审计统计
轻量基线	src/baselines/tfidf_lr.py	完成	字符 TF-IDF、手写 LR、结果保存
深度数据模块	src/data/datamodule.py	进行中	已补 CSV 读取，BERT 仍需 torch/transformers
KL 对齐	src/training/kl_loss.py	骨架完成	需接真实 BERT 特征
DANN	src/models/domain_discriminator.py	骨架完成	需跑 E5
测试验证	compileall + smoke run	进行中	语法检查和中期实验已通过

4. 中期实验结果与阶段性分析

模型方法	训练数据	tau	F1(source)	F1(target)	DeltaF1	AUC(target)	负面 Recall	正面 Recall
E0-lite: source TF-IDF+LR	源域 train	0.57	0.580	0.778	-0.197	0.875	1.000	0.500
E1-lite: source + target calibration	源域 + 目标域 train	0.45	0.733	0.829	-0.095	1.000	0.750	1.000

Midterm Smoke Benchmark: Target-domain Metrics



- 加入少量目标域校准后，目标域 Macro-F1 从 0.778 提升到 0.829，AUC 从 0.875 提升到 1.000。
- E1-lite 的正面召回从 0.500 提升到 1.000，但负面召回从 1.000 下降到 0.750，说明只优化 Macro-F1 会牺牲业务关键的负面召回。

#	样本	模型输出	正确答案	失败原因	改进方向
1	官方直播解释了关键疑问	E0-lite 预测负面	正面	源域缺少官方直播/疑问解释等社媒表达	目标域词表扩展或 BERT 语义表示
2	评论区全是水军正常意见被淹没	E1-lite 预测正面	负面	正常被误当正向，未理解水军/被淹没语境	加入网络用语词典与弱监督规则
3	处理方案只照顾少数人不公平	E1-lite 预测正面	负面	照顾偏正向，不公平才是决定性触发词	否定/公平性规则或上下文模型

5. 后续风险与冲刺排期

风险	状态	应对预案	
真实目标域数据不足	中期为样例 benchmark	第 13 周提交 5k+ 真实数据或脱敏下载脚本，并生成数据卡	
业务负面召回不稳定	E1-lite 负面召回为 0.750	阈值扫描加入 Negative Recall >= 0.85 约束	
深度模型未跑通	BERT/roBERTa 仍待联调	先小样本 smoke run，再跑 E1-E6	
贡献记录不足	Git 身份未覆盖全部成员	每人提交一个可审核模块或实验结果	
周次	核心任务	责任人	交付物/验收标准
第 13 周	替换为真实目标域数据，补数据卡，复跑 E0-lite/E1-lite	李乘黄、THAM WAN HEI	5k+ 数据或下载脚本；真实数据审计 JSON
第 14 周	跑通 BERT source-only、Adapter/LoRA、KL 对齐	马啸、化润宇	E1/E3/E4 三随机种子结果与 loss 曲线
第 15 周	完成弱监督、DANN、roBERTa 和完整消融	全员	E0-E6 消融表、KL/MMD、失败案例库
第 16 周	复查仓库、整理最终报告和答辩材料	全员	GitHub Release、最终报告、PPT、复现说明

6. AI 工具辅助使用记录与自查

场景	AI 工具	辅助环节	审查与纠错
开题报告	Claude	问题定义、实验设计草稿	人工审查后保留与代码一致路线
代码补全	GitHub Copilot	爬虫、数据处理、训练脚本补全	需 review 和测试
文献检索与 Debug	ChatGPT / Claude	DANN、KL 对齐资料与报错解释	仅作参考，结论由团队独立完成
中期闭环补全	Codex	local_loader、tfidf_lr、metrics、run.py、报告和 PDF	所有指标来自本地运行，明确样例不等同最终实验
自查项		状态	
GitHub 仓库公开且开题后有 commit		已满足	
本地中期补丁形成可运行代码闭环		已满足	
README 包含中期复现命令		已满足	
基线模型完整跑通并保存日志/JSON/CSV/图表		已满足	
E0-lite 与 E1-lite 已做定量对比		已满足	

自查项	状态
真实 5k+ 目标域数据	未完成，终期必须替换样例数据
所有组员至少 1 次 commit	未完全满足，需补齐 GitHub 身份映射